# یادداشت‌های پژوهشی — مدل کوچک (تیم پژوهشی ت)

## هدف

مقایسه سه مدل زبانی کوچک آفلاین برای تولید پاسخ مبتنی بر منبع در RAG Core، با شرط اجرا روی سخت‌افزار بدون GPU اختصاصی.

## مدل‌های نامزد

| کد | اندازه | کوانتیزاسیون | حافظه مصرفی |
|---|---|---|---|
| M-A | ۱٫۵ میلیارد پارامتر | ۸ بیتی | ۲٫۱ گیگابایت |
| M-B | ۳ میلیارد پارامتر | ۴ بیتی | ۲٫۴ گیگابایت |
| M-C | ۷ میلیارد پارامتر | ۴ بیتی | ۴٫۸ گیگابایت |

## نتایج آزمایش (۵۰ پرسش مرجع)

| مدل | میانگین JudgeScore (از ۲۰) | درصد پاسخ قبول (≥ ۱۸) | زمان پاسخ |
|---|---|---|---|
| M-A | ۱۴٫۹ | ۳۸٪ | ۱٫۸ ثانیه |
| M-B | ۱۷٫۴ | ۶۸٪ | ۳٫۱ ثانیه |
| M-C | ۱۸٫۶ | ۸۴٪ | ۷٫۹ ثانیه |

## مشاهدات

1. مدل M-A در پرسش‌های چندمرحله‌ای اغلب ارجاع به منبع را فراموش می‌کند.
2. مدل M-B بهترین توازن کیفیت و سرعت را دارد و نسخه فعلی RAG Core از آن استفاده می‌کند.
3. مدل M-C فقط وقتی حد قبولی ۱۸ را پاس می‌کند که زمان پاسخ بالا قابل‌تحمل باشد؛ زمان ۷٫۹ ثانیه از سقف ۸ ثانیه مصوب فقط اندکی کمتر است.
4. قالب PromptTemplate با نسخه `qa-grounded-v3` نرخ ارجاع‌دهی را از ۷۱٪ به ۸۹٪ رساند.

## کارهای باقی‌مانده

- تحویل ۸ سند نمونه باقی‌مانده (S-03 تا S-10) تا ۱۵-۱۱-۲۰۲۶.
- آزمون M-B با پرامپت انگلیسی-فارسی ترکیبی.
- هنوز هیچ نتیجه‌ای درباره آموزش مدل بنیادین به دست نیامده، چون خارج از دامنه است.